

V3 分子研究工作台项目报告

实现方法 计算能力与验收结果

报告日期 2026 年 9 月 29 日 面向课程教师与招新实操考核

1 项目概况

Molecule Studio V3 是一个可以在个人电脑上运行的分子研究工作台。用户输入 SMILES 后，可以获得分子结构、三种理化性质的模型估计及其适用范围；选择深入分析后，还可生成可旋转的三维构象并导出结构文件。数据库页提供实验记录和量化计算参考查询。

项目使用 FastAPI 提供 HTTP API，Uvicorn 运行服务。预测模型、数据库和网页都在本地，不需要付费 API 密钥。报告及交付包均以 V3 为对象。

模块	V3 已实现内容
模型计算	219 项二维描述符与 2048 位 Morgan 指纹；每个性质比较七个候选，按验证集选择单模型或双模型集成。
三维计算	ETKDGv3 采样与 MMFF94 优化；仅将收敛构象用于图形、相对能量和 SDF。
数据查询	14685 条实验性质观测；独立收录 130831 条 QM9 计算参考；精确结构、相似结构与来源筛选。
后端工程	异步任务、排队、取消、20 秒三维子进程时限、本地历史及明确错误响应。
前端交互	分析工作台、分子对比、双类别数据库、模型证据、交互三维、批量 CSV 与深浅色模式。
题目兼容	保留根目录 model.pkl 和纯 ESOL 随机森林接口，便于单独复核指定训练方案。

这些能力已通过代码检查、真实模型调用和浏览器操作验收。其用途是展示可复现的软件与计算流程；内部测试成绩不等于独立实验验证。

2 系统架构与 API 服务

API 是程序之间提交数据、接收结果的约定。本项目的网页只是其中一种调用方，Python 脚本或其他程序也能发送同样的 HTTP 请求。127.0.0.1 是当前电脑的地址；服务运行时才可访问。密钥是访问控制手段，不是 API 成立的必要条件。



图 1 V3 一次分析的主要流程 标准预测完成后，深入模式继续执行受时间限制的三维步骤。

接口	作用
POST /predict	同步多性质预测，保留 valid、molecule、logS_prediction、descriptor 等字段。
POST /analyses	提交 standard 或 deep 任务，立即返回 HTTP 202 与任务编号。
GET 或 DELETE /analyses/{id}	查询真实阶段和结果，或取消对应任务。
GET /analyses/{id}/conformers.sdf	下载已经完成的收敛构象合集。
GET /database/advanced	按文本、精确或相似结构查询实验参考，支持来源与性质筛选。
GET /quantum/search	查询 QM9 原有量化计算参考，不临时启动 DFT。
POST /assignment/predict	用根目录纯 ESOL 随机森林 model.pkl 重演题目基础预测。

一次请求怎样完成

```
POST http://127.0.0.1:8003/analyses
{"smiles":"CCO", "mode":"deep"}
```

```
GET http://127.0.0.1:8003/analyses/{返回的任务编号}
```

后台按“排队—性质预测—构象计算—完成”推进，前端轮询真实阶段。完成时，JSON 中的 predictions、measurements、descriptor 和 conformers 分别保存模型估计、数据库原值、结构描述符和三维结果。

默认只监听本机 8003 端口。目前没有公网托管、用户账号或密钥鉴权；本次交付没有把这些未完成的能力计入成果。

3 数据库与来源追溯

实验参考库用 SQLite 保存结构、原始观测、来源数据集和指纹索引。相同分子的多条记录保留各自来源，不把查询结果覆盖成一个“标准答案”。来源和性质筛选必须由同一条观测同时满足。

来源	原始行数	收录观测	主要性质
ESOL	1128	1128	水溶解度 logS
AqSolDB	9982	8718	水溶解度 logS
Lipophilicity	4200	4197	pH 7.4 的 logD
FreeSolv	642	642	实验水合自由能

实验库共 14685 条观测，覆盖 12843 个规范结构。训练时按结构身份归组；logS 重复来源优先使用 AqSolDB，并将与固定 ESOL 测试身份或骨架重叠的记录隔离。数据库记录量不等于独立训练样本数。

独立 QM9 计算参考库

V3 复用带哈希校验的 QM9 原始快照，并剔除官方列出的 3054 条几何一致性失败记录。最终收录 130831 条参考记录，对应 130744 个规范结构；同一结构的不同源编号仍分别保留。原作者特别标记的收敛问题会在命中记录中提示。

查询字段	页面单位	数值来源
偶极矩	Debye	文献 B3LYP/6-31G(2df,p) 计算
各向同性极化率	Bohr ³	同一 QM9 原始计算
HOMO 和 LUMO 能量	eV	由原始 Hartree 数值换算
HOMO - LUMO 能隙	eV	保留原表能隙，不以显示后舍入值重算

这些是已有计算的查询结果，没有用来训练三个实测性质模型，也不是本次运行新算的量子化学结果。库中主要是小型 H、C、N、O、F 分子；查不到某个结构时返回未命中，不填零、不推断任意大分子的轨道性质。

两个库存在跨库重复结构，不能把结构数直接相加。原始来源、CC0 数据许可记录、单位、排除列表和文件哈希位于 data/SOURCES.md、data/raw 与 reports/catalog_audit.json。

4 模型训练与选择方法

分子首先经 RDKit 解析并统一为规范结构。V3 生成 219 项固定顺序的二维描述符，包括分子量、氢键、环结构、拓扑、部分电荷和官能团计数，并生成 2048 位 Morgan 指纹。输入维数增加不等于预测精度必然提高，因此需要比较候选模型。

候选类型	使用的输入
随机森林	28 项基础描述符
ExtraTrees	28 项描述符+Morgan 指纹
ExtraTrees	219 项扩展描述符
直方图梯度提升	219 项扩展描述符
Ridge 正则回归	219 项描述符+Morgan 指纹
支持向量回归	219 项扩展描述符
ExtraTrees	219 项描述符+Morgan 指纹

七个候选及参数在拟合前写入训练协议。每个候选只用训练集拟合，并在验证集评分；仅在验证集排名前三的候选之间比较双模型组合。组合的权重非负且总和为一；只有验证 RMSE 至少改善 1% 才采用集成，否则保留最优单模型。确定成员和权重后，用训练加验证数据重新拟合。

目标	训练	验证	校准	测试
水溶解度 logS	6149	769	768	224
pH 7.4 分配系数	2664	410	410	615
水合自由能	469	46	46	78

划分保持完整分子骨架互不交叉，全部无环分子按同一骨架组处理。校准集只用于计算误差区间，测试集只用于最终报告；测试标签没有进入候选排序或集成权重拟合。各分区结构身份与骨架交集均为零。

无法计算的扩展描述符记为缺失，不填造化学数值。每个候选的中位数填补和标准化只在其拟合集上学习。主模型与训练共用同一特征实现，并核对 RDKit、scikit-learn 和特征版本。CPU 最多使用两个训练线程，特征以 float32 缓存到磁盘。

5 真实预测成绩与适用范围

性质	测试数	RMSE	MAE	R ²
水溶解度 logS	224	0.8256	0.6374	0.8415
pH 7.4 分配系数	615	0.7269	0.5514	0.6095
水合自由能	78	1.3424	1.0967	0.8038

表中 logS 与 logD 使用各自对数单位；水合自由能使用 kcal/mol。不同性质的 RMSE 不能横向当作同一尺度比较。同一固定测试集上的对比显示：logS 与 logD_{7.4} 的 RMSE 下降，水合自由能从 1.3339 略增至 1.3424 kcal/mol。升级并未改善每一个目标，本次保留验证集选择结果，没有据测试结果重挑模型。




图2 交付模型在全部固定测试行上的真实值与预测值 虚线表示预测等于观测，偏离距离反映误差。

性质	最终成员与权重
水溶解度 logS	梯度提升 219D 52.7%；ExtraTrees 219D+指纹 47.3%
pH 7.4 分配系数	支持向量回归 219D 54.0%；梯度提升 219D 46.0%
水合自由能	Ridge 219D+指纹 55.1%；ExtraTrees 219D 44.9%

性质	名义覆盖	实际测试覆盖	平均区间全宽
水溶解度 logS	90%	95.98%	3.682
pH 7.4 分配系数	90%	85.85%	2.095
水合自由能	90%	100.00%	12.172

RMSE 和 MAE 越小越好；R² 不是预测正确率。logS 相差一个单位，浓度相差十倍。名义 90% 区间来自独立校准集残差，不保证任意新分子的覆盖。尤其水合自由能只有 46 个校准样本，应同时阅读区间宽度。

未达到名义水平：pH 7.4 分配系数 实际覆盖 85.85%。本次保留这个结果，没有针对测试集重新调整区间。

指标使用固定内部测试集，并已在开发过程中查看过；本次没有获得新的外部实验验证。模型遇到明显过大、特征越界的结构会隐藏数值与成员预测，通过筛查也不证明可靠。

6 深入分析与计算耗时

深入模式先运行与标准模式相同的性质模型，再在独立进程中生成三维构象。ETKDGv3 最多请求 16 个构象，按几何相似程度去重，再用 MMFF94 优化。页面可旋转球棍图、切换构象并比较同一分子的相对能量。

只有优化收敛的构象进入图形、形状描述符和 SDF。若没有收敛构象，则返回明确失败状态。三维步骤不直接改变三个二维机器学习模型的预测，也不计算 DFT、溶液相自由能或跨分子的相对稳定性。

计算约束	实际处理
单任务时间	三维子进程最多 20 秒，包含启动时间；超时停止该进程并保留已完成的性质预测。
队列与取消	单分析 worker，最多八个待处理任务；取消正在运行的任务会回收对应子进程。
结构规模	重原子超过 60、可旋转键超过 12 或加氢后超过 200 原子时跳过深入步骤。
参数与失败	缺少 MMFF94 参数、无法嵌入、未收敛、取消与超时分别报告，不制造占位结果。

样例	标准分析	深入分析	收敛构象数
乙醇	0.79 s	1.79 s	1
阿司匹林	0.42 s	1.60 s	2
咖啡因	0.43 s	1.77 s	1
对乙酰氨基酚	0.44 s	1.73 s	2
山梨醇	0.45 s	2.01 s	16

上述是当前 Windows 电脑上的五种普通分子，每种模式各运行一次，计入 HTTP 提交与轮询时间。硬件为 Intel Core i7-13700H、16 GB 内存；时间会受负载和结构复杂性影响，不代表任意输入或高并发的保证。最近任务保存在独立的本地工作记录库，保留最近一百个终态任务。实验与 QM9 参考库不被计算历史修改；交付压缩包也不包含个人历史和临时构象附件。

7 前端工作台与操作验收

页面围绕分析、对比、参考数据库和模型证据组织。输入修改后会清除旧结果；用户可以读取完整 JSON，查看未命中、范围外或失败原因，而不是只看到一个缺少来源的预测数值。



图 3 V3 实际深入分析页面 三维坐标与构象来自本机 MMFF94 计算，不使用示意数值替代结果。

交互	实现要点
结构查看	二维与交互三维切换；拖动旋转、滚轮缩放、键盘控制和构象选择。
分子对比	最多四个结果并排显示，保留单位、区间与适用范围状态。
批量与导出	粘贴或 CSV 导入最多 50 行；逐行保留错误；JSON、CSV 和 SDF 各自保留相应信息。
移动端与外观	响应式布局、深浅色模式；关键操作和错误提示可在小屏幕访问。

页面数值区分模型估计、结构计算、实验记录和文献计算参考。模型证据页可以追溯候选评分、最终成员、测试样本数量与区间覆盖，而不把算法复杂程度当成正确性证明。

8 验收结果与题目对应

验收层面	实际结果	证据文件
自动测试	86 项通过，0 失败，0 跳过	reports/automated-tests.txt
真实 HTTP 样例	65 项断言通过；十次分析	reports/live_acceptance.json
浏览器工作流	23 项实际检查通过	reports/browser-qa.json
数据与模型追溯	哈希、划分隔离、校准与全部测试预测重算	reports 下各性质审计文件

自动验收包含非法输入、部分模型缺失、结构范围外数值遮蔽、数据库筛选、缺失索引降级、真实构象与 SDF 回读、排队和运行中取消、超时及服务关闭回收。真实模型审计重新计算全部测试预测与指标，避免报告和交付模型脱节。

与实操题核心要求对应

题目要求	V3 对应实现
Python API 与 POST /predict	FastAPI 实际路由；含 smiles 的 JSON 输入和题面要求的核心输出字段。
RDKit 处理分子	解析、规范化、MW、LogP、HBD、HBA、TPSA、二维结构图及扩展描述符。
ESOL 与指定算法	独立题目兼容模型使用 ESOL 实测标签及 RandomForestRegressor；主模型是扩展方案。
保存并加载 model.pkl	根目录保留纯 ESOL model.pkl；题目兼容接口启动加载、请求时复用。
网页与测试截图	单分子网页、输入提示、结果展示、真实浏览器记录及截图随包提供。

需要说明的差异是：主系统 /predict 使用多数据源扩展模型；纯 ESOL 指定算法通过 /assignment/predict 单独复核。若评阅只允许题面原始方案，应使用这个明确标记的兼容入口，不能把主模型成绩当作纯 ESOL 成绩。兼容接口阿司匹林实际响应约为 $-1.9999771 \log S$ 。

本报告描述已完成的本地实现与验收。未执行题目所列邮箱发送，也没有将工程测试等同于独立化学实验。

9 交付内容与复现方法

V3 压缩包包含前后端源码、三个主模型及题目兼容模型、两个参考数据库、原始快照、训练脚本、固定依赖、测试、截图和本报告。启动不需要安装 Node.js。虚拟环境、个人计算历史和训练中间缓存不进入交付包。

在当前电脑或新环境运行

```
当前电脑 在 V3 项目目录执行
.\start.ps1

新电脑 先安装 Python 3.12
py -3.12 -m venv .venv
.\.venv\Scripts\python.exe -m pip install -r requirements.txt
.\start.ps1

自动验收
.\start.ps1 -Test
```

默认访问 <http://127.0.0.1:8003/>；接口文档在 /docs。模型序列化与 RDKit 特征依赖指定软件版本，换版本后应重新训练并核验。新电脑第一次安装依赖需要网络，正常网页预测与数据库查询可离线运行。

复核目标	入口
使用 API	README.md；docs/API_EXAMPLES.json；浏览器 /docs
候选协议与验证选择	reports/〈性质〉/training_protocol.json 和 validation_predictions.csv
预测与误差	reports/〈性质〉/test_predictions.csv 和 metrics.json
原始数据与许可	data/SOURCES.md、data/raw、reports/catalog_audit.json
自动与浏览器验收	reports/automated-tests.txt、live_acceptance.json、browser-qa.json
归档完整性	PACKAGE_MANIFEST.json 记录文件 SHA-256；打包后另核 ZIP CRC、解压哈希及接口运行。

尚未完成的验证

当前没有新实验测量、独立外部数据验证、多次独立划分的稳定性研究或生产并发测试。开发使用的固定测试集并非全新的盲测集。区间、结构相似度和构象收敛都只能支持各自范围内的结论，不能据此作出药效、毒性或临床判断。

主要方法来源：RDKit 官方文档 https://www.rdkit.org/docs/RDKit_Book.html；QM9 原始研究 DOI 10.1038/sdata.2014.22；ESOL 原始研究 DOI 10.1021/ci034243x。完整数据库来源与许可可见包内 SOURCES.md。